

Project Work di Explainable Artificial Intelligence

Emiliano Lorenzo

1 Introduction

Questo Project Work si concentra sull'utilizzo di tecniche di Explainable Artificial Intelligence (XAI) nel contesto delle Space Observations. Nello specifico, le osservazioni considerate in questo progetto provengono dal radar MARSIS installato sulla sonda della missione Mars Express dell'ESA (European Space Agency) [1] volta all'analisi di Marte, con lo scopo di individuare elementi adatti alla vita umana, come la presenza di acqua. A questo proposito, il radar viene usato per l'invio di onde elettromagnetiche che, una volta riflesse dalla superficie e dal sottosuolo marziani, se analizzate permettono di comprenderne la composizione. Dati i vincoli intrinseci della missione, le risorse a disposizione per la memorizzazione e l'elaborazione dei dati sono molto contenute. La finestra temporale quotidiana per la rilevazione dati ammonta a circa 2 minuti, pertanto è fondamentale ottimizzare lo scheduling delle rilevazioni in base alle condizioni che più verosimilmente rendano favorevole tale operazione. In questo contesto, in [2] vengono impiegate tecniche di Intelligenza Artificiale (AI) per analizzare le condizioni sperimentali al contorno e predire la qualità del segnale radio in istanti futuri, allo scopo di usare tali predizioni per poi programmare le rilevazioni future in modo ottimizzato. Tale studio introduce anche l'uso di tecniche di XAI per spiegare su quali feature si basano le predizioni dell'AI, allo scopo di rendere gli output del modello interpretabili da esperti del settore. Questo Project Work si focalizza sullo studio di una feature in particolare, l'Indice di intensità del Flusso Solare ($F_{10.7}$ index). Negli studi citati questa feature non è stata considerata poiché tradizionalmente considerata imprevedibile. Secondo la fisica tale feature ha però una grande importanza nei risultati di qualità del segnale radio, in contesti spaziali come quello qui in esame. A questo proposito questo progetto introduce tale feature all'interno del sistema sviluppato in [2] e ne valuta l'impatto. Nello specifico, il lavoro seguente si articola in questo modo:

- **Exploratory Data Analysis (EDA):** Analisi esplorativa dei dati (EDA) ed individuazione di tendenze ed eventuali pattern.
- **Training delle neural networks con $F_{10.7}$ index:** Addestramento dei migliori modelli risultanti dagli studi precedenti considerando anche l'indice $F_{10.7}$ come feature e successiva interpretazione con SHAP [3].
- **Training Explainable Boosting Machines (EBMs):** Addestramento EBMs [4] con $F_{10.7}$ index come feature e confronto con le reti neurali.
- **Predizione di $F_{10.7}$ index e addestramento in cascata delle reti neurali:** Utilizzo di predittori (regressione lineare e LSTM [5]) per prevedere l' $F_{10.7}$ index e valutazione delle performance delle reti neurali sui dati con tale feature al posto del valore reale di $F_{10.7}$ index.

2 Exploratory Data Analysis

I dati a disposizione sono in formato csv, in cui ogni riga del file corrisponde ad una rilevazione (un sample) ed ogni colonna ad una feature. Per una trattazione più approfondita sull'assemblaggio del dataset leggere [2]. La EDA portata avanti in questo progetto si focalizza sull' $F_{10.7}$ index, allo scopo di investigare la natura di questa feature e il suo rapporto con la variabile target, per meglio implementare il successivo training dei modelli. Inizialmente è stata analizzata la forma della distribuzione del target, il Peak Power, ovvero la qualità del segnale radio di risposta. E' stata plottata la distribuzione originale dei dati (immagine sinistra Figura 1) contrapposta alla sua trasformazione con $\log_{10}$ (a destra).




Figure 1: Distribuzione della variabile Target - Peak Distorted Echo Power

Dalla Figura 1 si può osservare come l'assunzione di normalità non valga pienamente, con la distribuzione dei dati originale caratterizzata dall'assenza del tipico picco della normale, sostituito invece da un plateau. La trasformazione con $\log_{10}$ peggiora la situazione, aumentando l'asimmetria. I valori di skewness e curtosi riportati nei grafici confermano questi fatti. In base a ciò, si può concludere che una trasformazione $\log_{10}$ non gioverebbe al training, portando pertanto a considerare di implementare una semplice standardizzazione. Il secondo esperimento fatto riguarda la valutazione dell'autocorrelazione dei dati dell' $F_{10.7}$ index. A questo scopo, è stato calcolato il coefficiente di correlazione di Pearson tra la serie storica della feature al tempo t e la stessa serie traslata con lag da 1 a 40 steps temporali. In Figura 2 è riportato il grafico ottenuto.




Figure 2: Valori di autocorrelazione per l' $F_{10.7}$ index.

Si può osservare come l'ipotesi di autocorrelazione tra i dati sia completamente confermata dalle evidenze sperimentali, con i valori di Pearson significativamente più alti dell'intervallo di confidenza, i cui bordi (linea rossa tratteggiata) risultano addirittura sovrapposti data la differenza di scala. Questo fatto giustifica l'utilizzo di modelli predittivi come le LSTM (Long Short-Term Memory [5]) che si basano proprio sull'ipotesi di autocorrelazione nei dati.

In seguito, per esplorare le dipendenze intercorrenti tra le feature fornite al modello, è stata realizzata una heatmap della matrice di correlazione di Spearman. I dendrogrammi ai margini della figura, generati tramite clustering gerarchico, evidenziano visivamente le variabili che presentano comportamenti congiunti.

Analizzando i risultati, emerge che la componente tangenziale e l'intensità totale del campo magnetico locale presentano un'elevata correlazione positiva (0.89); tale dipendenza è attesa, essendo la prima una componente vettoriale fondamentale per il calcolo della seconda. Per quanto riguarda l'indice $F_{10.7}$, si osserva una marcata dipendenza con le principali variabili legate all'illuminazione solare, nello specifico con la distanza Marte-Sole (`FM_data.Mars.Sun.distance`, 0.67) e con l'angolo di elevazione solare (`FM_data.Sun.elevation_angle`,




Figure 3: Heatmap basata sulla correlazione di Spearman tra features.

-0.67). È interessante notare come l'indice $F_{10.7}$ sia inversamente correlato (-0.55) anche con la banda operativa del radar (FM_data_band). Tale legame si spiega considerando che la selezione del parametro strumentale dipende dalle condizioni della ionosfera marziana, la cui densità è a sua volta fortemente modulata dall'attività solare.

Infine, l'ultima analisi effettuata riguarda la relazione tra il target degli esperimenti generali, ovvero il Peak Power per la qualità del segnale radio, e l' $F_{10.7}$ index. In Figura 4 si osserva chiaramente come dal fit dei samples considerati (punti scuri sullo sfondo) emerga un trend non lineare. Questo giustifica l'uso di modelli come reti neurali o EBM, in grado di catturare tale tipo di trend, per la predizione del target.

3 Addestramento delle reti neurali mantenendo la feature $F_{10.7}$

Per gli esperimenti presenti in questa sezione è stata usata la rete neurale proveniente dallo studio originale [2], considerando che in tale studio essa era stata individuata come il miglior modello di machine learning per il task di predizione della qualità del segnale radar. Si tratta di una rete con struttura di tipo Multilayer Perceptron (MLP) Feed Forward con funzioni di attivazione ReLU. La rete è costituita da layer lineari di, rispettivamente, 800, 400, 200, 100, 1 neuroni. Gli esperimenti di tutto il progetto sono stati condotti su una Workstation Linux dotata di 2 GPU NVIDIA GeForce RTX 2080 SUPER. Tutti gli esperimenti della sezione 3 sono stati effettuati facendo ricorso alle procedure di K-Fold Cross Validation e standardizzazione dei dati descritte in [2].

3.1 Confronto delle metriche: TensorFlow e PyTorch

Il training delle reti neurali in questo progetto è stato portato avanti usando la libreria PyTorch, differenziandosi dal lavoro originale che invece faceva ricorso a TensorFlow/Keras. Allo scopo di verificare di aver effettuato una corretta traduzione del codice originale, da usare come baseline, la stessa rete neurale è stata addestrata sia con la pipeline TensorFlow/Keras che con quella PyTorch, confrontandone poi i risultati in




Figure 4: Rapporto tra la variabile target da predire e l' $F_{10.7}$ index.

termini di performance. In Figura 5 è presente la comparazione tra il MAE (Mean Absolute Error) ottenuto con il codice TensorFlow e quello ottenuto con PyTorch (in entrambi i casi senza considerare l' $F_{10.7}$ index tra le feature).




Figure 5: Confronto del MAE tra codice TensorFlow/Keras e PyTorch

Si può notare come le performance siano sostanzialmente coincidenti, a testimonianza del fatto che la traduzione da un framework all'altro non ha inquinato i risultati dell'esperimento.

3.2 Confronto prestazionale: inclusione ed esclusione di $F_{10.7}$

Per valutare l'impatto della feature $F_{10.7}$ sulle predizioni della rete neurale, sono state confrontate le performance di tale modello addestrato sia sui dati privi dei valori dell'indice $F_{10.7}$ (la baseline descritta nel paragrafo precedente) sia sul dataset comprensivo anche di tale indice. Osservando la figura 6 si nota come, in termini di MAE, le prestazioni rimangano molto simili su tutti i fold.

Considerando la Figura 7, invece, in cui la metrica impiegata è il Mean Squared Error (MSE), è possibile osservare come, sul Fold 9, sia presente un netto miglioramento di tale indicatore nel caso in cui l' $F_{10.7}$ index




Figure 6: Confronto delle performance del modello nel caso con $F_{10.7}$ index vs senza

sia mantenuto tra le feature. Questa differenza verrà investigata in modo più approfondito in seguito, anche se per adesso è comunque possibile ipotizzare che essa sia dovuta al fatto che l'MSE amplifica i valori a causa della sua natura quadratica. Di seguito sono riportate le formule matematiche di MAE ed MSE, che supportano questa idea.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (1)$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2)$$




Figure 7: Confronto delle performance del modello nel caso con $F_{10.7}$ index vs senza

In figura 8 sono invece riportati gli andamenti di Training e Validation Loss (misurata come MSE) sul Fold 9. Anche in questo caso è possibile osservare l'apporto positivo rappresentato dall' $F_{10.7}$ index.

3.3 Valutazione dell'impatto della dimensione del batch

Tutti gli esperimenti descritti in precedenza all'interno di questa sezione sono stati effettuati considerando una dimensione del batch pari a 32. In questo paragrafo vengono invece riportati i risultati, in termini di MAE, ottenuti considerando un valore di batch size pari a 256 samples. Tali risultati sono ottenuti considerando




Figure 8: Andamento della Loss Function nel caso con $F_{10.7}$ index vs senza

l' $F_{10.7}$ index tra le feature e sono confrontati con i risultati ottenuti con batch size pari a 32 samples (sempre considerando l' $F_{10.7}$ index).




Figure 9: Confronto batch size= 32 vs batch size = 256 (mantenendo in entrambi $F_{10.7}$ index)

Si può osservare come le performance rimangano sostanzialmente invariate nonostante la differente dimensione del batch, portando quindi a concludere che tale iperparametro non sia rilevante (rimanendo nell'intervallo tra 32 e 256) per lo studio oggetto di questo progetto.

4 Spiegazione dei risultati della rete neurale con SHAP

Allo scopo di investigare i principali fattori che hanno determinato i risultati dettagliati nella sezione precedente e rifacendosi a quanto presentato in [2], in questa sezione è presente un'analisi della rete neurale impiegata negli esperimenti descritti, usando SHAP [3]. SHAP è una tecnica di XAI post-hoc che si basa sulla Teoria dei Giochi cooperativa: le feature sono modellate come giocatori che collaborano per ottenere una predizione, con l'importanza di ogni feature assegnata in base al contributo che essa apporta. Negli studi recenti, SHAP è una delle tecniche più usate per l'interpretabilità di modelli black-box come le reti neurali. Per l'implementazione si è fatto ricorso alle API offerte dalla libreria originale [6].

4.1 SHAP macro-error analysis su Fold 1 e Fold 5

Nel contesto di questo progetto, SHAP è stato applicato ai risultati dell'esperimento con batch size pari a 256, che si è rivelato essere molto vicino, in termini di prestazioni, al caso con batch size pari a 32. Considerando che il Fold 5 risulta essere il fold con le metriche di errore più alte, mentre il Fold 1 uno di quelli migliori

(vedere Figura 9), è stata effettuata un'analisi comparativa tra questi 2 fold. Di seguito sono riportati (Figura 10) i beeswarm plot risultanti da tale analisi.




Figure 10: Beeswarm plots Fold 1 e Fold 5.

Da tali plot si possono osservare risultati interessanti. Innanzitutto, le variabili che caratterizzano in modo più significativo l'output del modello sono sempre le stesse, ovvero il Sun elevation angle, la distanza tra Marte e il Sole e le feature legate al campo magnetico. Questo è in linea con quanto ci si aspetta dalla teoria, dal momento che è noto come queste variabili impattino fortemente sull'atmosfera marziana che è il mezzo attraverso cui dovranno propagarsi le onde radio. Un fatto che è sicuramente di rilievo è l'assenza dell' $F_{10.7}$ index dal gruppo delle variabili più importanti, per entrambi i fold. Questo fatto però può essere spiegato facendo ricorso alla heatmap basata sulla Correlazione di Spearman presentata in precedenza. In tale grafico si nota infatti come l' $F_{10.7}$ index sia fortemente correlato alla distanza Marte-Sole, portando quindi al fenomeno della multicollinearità: un gruppo di feature fortemente correlate tra loro che portano informazioni ridondanti al modello. In uno scenario del genere, i modelli di AI tendono a usare solo alcune delle feature dando poca importanza alle altre. Questo sostiene l'ipotesi che, in questo caso specifico, il modello si sia affidato alla distanza Marte Sole trascurando l' $F_{10.7}$ index poichè ritenuto ridondante. A questo punto, per avere un riscontro dalla realtà fisica, è stato realizzato un plot che confrontasse l'andamento dell' $F_{10.7}$ index nel tempo con la divisione dei dati in fold, operata in modo statico (senza usare lo shuffling). In Figura 11 è possibile osservare tale andamento.

Qui si apprezza chiaramente come il valore di $F_{10.7}$ index sia effettivamente aumentato in corrispondenza del Fold 5 e degli altri fold in cui le performance del modello sono risultate essere peggiori, a testimonianza dell'importanza di tale variabile. I plot di SHAP riportano però un'importanza contenuta dell' $F_{10.7}$ agli occhi del modello, sia per il fenomeno della multicollinearità analizzato in precedenza, sia per il fatto che verosimilmente la rete ha overfittato sulle condizioni ordinarie, in cui le features rilevanti sono altre, e quindi ha faticato a dare importanza all' $F_{10.7}$ in condizioni diverse dal regime normale di training, come accade nel Fold 5. Questo fatto rafforza l'ipotesi che l' $F_{10.7}$ index sia una feature importante, soprattutto in scenari diversi dalle condizioni di addestramento ordinarie.




Figure 11: Sovrapposizione dell'andamento di $F_{10.7}$ index alla divisione in fold del dataset

4.2 SHAP micro analysis su Fold 1 e Fold 5

In questa sezione viene portata avanti un'analisi specifica su alcuni samples del Fold 5. Tale analisi si avvale sempre del metodo SHAP e mira ad individuare l'importanza delle singole feature nella determinazione dell'output per un certo campione. Di seguito è riportato uno dei grafici ottenuti per i samples detti.

Il grafico, presente in Figura 12, conferma a livello locale i risultati globali del beeswarm plot. In particolare, è possibile osservare come la distanza tra Marte e il Sole sia anche in questo caso la feature più rilevante per le predizioni del modello. L' $F_{10.7}$ index non risulta presente tra le feature più importanti, probabilmente a causa del ruolo giocato dalla multicollinearità descritto in precedenza.

4.3 Analisi del Fold 9

Con riferimento alle sezioni precedenti, un fold di particolare interesse è il Fold 9, per il quale è stata riscontrata una forte differenza, in termini di MSE, confrontando il caso in cui l' $F_{10.7}$ index è presente tra le feature e il caso in cui invece non lo è. A questo proposito, è stato realizzato un Dependence Plot (presente in Figura 13) che documenta lo Shapley value assegnato da SHAP ad ogni determinato valore di $F_{10.7}$ index. Il comportamento presente è a gradino, sottolineando come la relazione tra le 2 grandezze considerate sia fortemente non lineare, con due cluster di punti in zone diverse del grafico.

In Figura 14 è invece presente il Waterfall Plot relativo ad uno dei samples del Fold 9 in cui sono state registrate le peggiori prestazioni del modello. Si può notare come, in questo caso, il contributo dell' $F_{10.7}$ index sia molto rilevante, a testimoniare l'impatto di tale variabile nello scenario considerato, caratterizzato da un regime diverso da quello ordinario di training a cui la rete neurale si è adattata.

5 Applicazione delle Explainable Boosting Machines

Le Explainable Boosting Machines (EBMs) [7] sono modelli ensemble basati sul training di una serie di alberi di decisione. Differiscono dalle reti neurali per la loro natura intrinsecamente spiegabile. In questo progetto, esse sono state valutate per avere un confronto tra le performance di metodi black box (come le reti neurali per l'appunto) e metodi interpretabili by design, nel contesto del problema della predizione della qualità del segnale radio per la rilevazione di dati da Marte.

Nella Tabella 1 è presente un confronto delle performance, in termini di MAE e MSE, tra la rete neurale degli esperimenti precedenti (addestrata in questo caso con un batch size di 256 samples) e il modello EBM considerato. La EBM presenta delle performance lievemente peggiori rispetto alla rete neurale, ma comunque dello stesso ordine di grandezza e quindi perfettamente accettabili. In compenso, il modello EBM è, come detto, interpretabile by design e quindi offre notevoli vantaggi per quanto riguarda l'analisi dei dati oggetto di questo progetto. Un altro dettaglio da sottolineare è che la EBM è stata addestrata con dati non normalizzati,




Figure 12: Plot derivante dalla micro analysis con SHAP di un sample del Fold 5




Figure 13: Plot della relazione tra valore di $F_{10.7}$ index e relativo Shapley value.




Figure 14: Waterfall plot per un sample del Fold 9.

Table 1: Confronto delle metriche MAE e MSE mediante K fold cross validation cronologica a 10 fold. Le prestazioni dell’Explainable Boosting Machine (EBM) sono valutate rispetto a quelle della rete neurale (dimensione del batch = 256), con e senza l’indice di flusso solare tra le feature. I risultati migliori per ciascun fold sono evidenziati in grassetto.

Fold	EBM		Neural Network (BS=256, con Flusso)		Neural Network (BS=256, senza Flusso)	
	MAE	MSE	MAE	MSE	MAE	MSE
Fold 0	4.120	27.117	2.374	10.274	2.984	14.233
Fold 1	3.773	22.069	2.491	10.007	2.467	10.016
Fold 2	3.723	21.159	2.509	10.080	2.526	10.144
Fold 3	3.560	19.567	2.876	13.746	3.167	16.961
Fold 4	5.488	48.083	4.038	27.571	3.978	26.979
Fold 5	6.016	64.412	5.161	45.319	5.035	45.713
Fold 6	5.056	45.724	4.662	38.438	4.603	37.777
Fold 7	5.189	40.636	3.456	22.024	3.385	21.321
Fold 8	4.600	32.905	2.871	12.245	3.652	22.033
Fold 9	3.688	21.690	2.396	10.760	2.527	11.430
Global	4.521	34.336	3.283	20.046	3.432	21.661

contrariamente a quanto fatto per la rete neurale e a come si fa solitamente per i modelli di deep learning. Per le EBM, infatti, è importante solamente l'ordinamento dei dati, e lasciare tali dati nella scala originale rende più spiegabili le scelte del modello, basate sul confronto di ogni sample con le soglie interne agli alberi. Di seguito sono presentati dei grafici ottenuti a partire dalla EBM usando le API della libreria InterpretML [4], impiegata in questo contesto per l'implementazione di questa classe di modelli.




Figure 15: EBM feature importance plot.

Dal plot in Figura 15 è possibile osservare come l' $F_{10.7}$ index risulti essere la terza feature in ordine di importanza, a testimonianza di quanto la EBM in questione si affidi a tale variabile per le sue predizioni. Con questa tipologia di modello emerge in modo più netto la rilevanza del flusso solare rispetto al caso delle reti neurali, dove probabilmente a causa della multicollinearità il modello prediligeva l'uso di altre feature correlate, in primo luogo la distanza tra Marte e il Sole. In Figura 16 è invece presente un plot specifico che riporta la distribuzione dei dati, in termini di densità di samples per intervallo di valori di flusso solare, comparata agli output del modello. Appare evidente come, in zone più ricche di dati, come l'intervallo di valori bassi dell' $F_{10.7}$ index, la EBM impari a riconoscere pattern più dettagliati producendo un profilo più frastagliato. Nelle zone con maggiore scarsità di dati, invece, la EBM individua alcune regole generali e le applica a tutti i samples, risultando in un andamento più piatto.

In conclusione di questa sezione, è possibile affermare che l' $F_{10.7}$ index gioca un ruolo molto rilevante nel contesto delle predizioni fornite dalle EBM. Tale feature risulta avere un peso elevato, osservando i plot forniti dal modello. La discrepanza tra questo risultato e gli output di SHAP è probabilmente dovuta alla natura intrinsecamente diversa delle tecniche considerate. SHAP è un'interpretazione post-hoc del comportamento di modelli, applicata in questo caso a un MLP che apprende le feature in modo denso e quindi predilige quelle più regolari: la distanza Marte-Sole rispetto all' $F_{10.7}$ index in questo caso. Le EBM, per la loro impostazione ensemble additiva e considerando il fatto che nel training il parametro delle interazioni è stato posto a 0, addestrano un modello per ogni feature, riuscendo ad isolare l'apporto di tale feature e quindi aggirando i




Figure 16: $F_{10.7}$ index importance plot.

problemi dati dalla multicollinearità.

6 Predizione dell' $F_{10.7}$ index

Appurato che la feature $F_{10.7}$ index esercita un notevole peso per quanto riguarda il task considerato in questo progetto, sono state esplorate varie strategie per integrarla nel flusso di lavoro della rete neurale MLP. In questa sezione viene considerato proprio l'MLP come modello predittivo designato alla luce delle buone performance riscontrate e presentate nelle sezioni precedenti.

In primo luogo, è stata generata una variante del dataset originale in cui la colonna dell' $F_{10.7}$ index è stata modificata inserendo, al posto dell'effettivo valore di $F_{10.7}$ index del mese corrente, il valore del mese precedente. Questo è stato fatto allo scopo di valutare se la dipendenza temporale riguardante questa feature, osservata durante la EDA, potesse sopprimere o meno alla difficoltà predittiva dell' $F_{10.7}$ index. In seguito, si è passati alla fase di effettiva predizione. Innanzitutto è stato addestrato un modello di regressione lineare sui dati dell' $F_{10.7}$ index, per costituire una baseline per tutti gli altri esperimenti predittivi successivi. Successivamente, sono stati addestrati dei modelli LSTM per predire l' $F_{10.7}$ index, sostituendo tali predizioni ai valori dell' $F_{10.7}$ index nel dataset di Test. Il dataset di training è stato lasciato invariato, allo scopo di simulare uno scenario realistico in cui l'MLP viene addestrato su dati storici risultanti da misurazioni, e quindi comprensivi dell' $F_{10.7}$ index, e poi usato per generare predizioni sulla base di dati futuri stimati con un modello LSTM. Di seguito sono comparati i risultati delle predizioni del modello considerando i dati reali, i risultati usando il lagged dataset con lag pari a 1 mese e, infine, usando le predizioni della LSTM per l' $F_{10.7}$ index al posto dei dati reali. Per quanto riguarda le predizioni della LSTM, sono state testate 2 strategie, entrambe a partire dal dataset originale splittato in modo da avere l'80 per cento dei dati come valori storici e il 20 per cento come target dell'orizzonte temporale da prevedere. La prima strategia è più basilare e consiste nel passare tutti i dati storici alla LSTM e farle predire, in un colpo solo, tutti i dati relativi all'orizzonte temporale, da inserire poi nel dataset. La seconda strategia, invece, consiste nell'addestrare la LSTM a prevedere i valori del mese futuro basandosi su quelli dei mesi precedenti. Quest'ultima strategia rappresenta in modo più aderente uno scenario reale di impiego e quindi vengono considerate le performance ad essa riferite nel seguito della discussione.

In Tabella 2 sono confrontate le performance ottenute con la rete MLP usando i dati dell' $F_{10.7}$ index del

Table 2: Confronto delle performance Fold per Fold: Modello con Dati Reali vs. Modello con Dataset Lagged

Fold	Dati Reali		Dataset Lagged	
	MAE	MSE	MAE	MSE
0	2.374	10.274	2.913	12.793
1	2.491	10.007	2.538	10.888
2	2.509	10.080	2.520	10.126
3	2.876	13.746	3.151	18.735
4	4.038	27.571	4.094	30.227
5	5.161	45.319	5.536	52.965
6	4.662	38.438	4.495	36.535
7	3.456	22.024	3.631	25.809
8	2.871	12.245	2.519	10.477
9	2.396	10.760	2.520	10.992
Global	3.283	20.046	3.392	21.955

dataset originale e usando il lagged dataset. Le performance risultano essere molto vicine, a conferma del fatto che la forte autocorrelazione presente nei dati permette al modello di adattarsi e lavorare bene anche con dati arretrati di un mese. Questo è un fatto che giustifica l'utilizzo di predittori come le LSTM per stimare i dati futuri e usare poi tali stime come feature per le predizioni del modello MLP. Di seguito sono riportati i risultati anche di tale esperimento.




Figure 17: Confronto tra output del modello con dati reali vs scenario a cascata con LSTM.

In Figura 17 sono rappresentate, tramite scatter plot, le predizioni del modello MLP ottenute usando i dati reali e quelle ottenute, con lo stesso modello, usando i dati predetti dalla LSTM. Si può osservare come i due gruppi di punti si sovrappongano quasi esattamente, testimoniando come le stime fornite dalla LSTM siano più che sufficienti al modello MLP per prevedere la qualità del segnale radio in condizioni future di osservazione. In Tabella 3 sono presenti le metriche globali di questo esperimento in cascata con LSTM e

MLP, comprensive dello scostamento percentuale nelle performance tra i due scenari considerati. E' possibile notare come questi dati supportino ulteriormente l'ipotesi di sfruttare le stime di modelli predittivi come feature per la rete MLP, fatto che i dati testimoniano non inficiare le performance del sistema generale.

Table 3: Scenario a Cascata

Scenario	MAE
Scenario 1: True Flux	2.7622
Scenario 2: Predicted Flux WF	2.7577
Performance Degradation	-0.16%

6.1 Ulteriori considerazioni sulle predizioni dei modelli LSTM

Allo scopo di valutare l'effettiva aderenza delle predizioni del modello LSTM ai dati reali dell' $F_{10.7}$ index, è stata effettuata un'analisi volta a confrontare le principali caratteristiche delle due distribuzioni. In figura 18 sono comparate le due distribuzioni sovrapponendo i rispettivi istogrammi e riportando le medie di entrambe. Appare evidente come, sia in termini di media che di distribuzione dei dati, la LSTM riesca a rimanere estremamente aderente alla ground truth.

Anche i valori della Distanza di Wasserstein tra la distribuzione dei dati originali e quella predetta dalla LSTM confermano in modo ulteriore questo fatto, rimanendo molto contenuti per ogni misurazione.

7 Conclusioni

Questo progetto si è concentrato sullo studio dell' $F_{10.7}$ index e sulla verifica della sua importanza, come feature, nella predizione della qualità del segnale radio da parte di modelli AI. Tali predizioni sono molto utili, come discusso in precedenza, allo scopo di organizzare la rilevazione di dati da Marte da parte della sonda della missione ESA Mars Express. Il contesto operativo di tale sonda è infatti caratterizzato da vincoli stringenti per quanto concerne la memoria e le finestre temporali in cui operare, pertanto è necessaria un'accurata pianificazione, in precedenza svolta manualmente e adesso integrata con le predizioni di modelli di machine learning. In questo contesto, la feature $F_{10.7}$ index era stata inizialmente esclusa dagli input forniti alla rete neurale impiegata per le predizioni, ritenendo tale feature non predicibile e quindi non utilizzabile. In questo progetto è stata dimostrata, facendo ricorso a tecniche di XAI, l'importanza di questa feature, confermando quanto già previsto dalla fisica. Inoltre, tramite gli esperimenti con modelli predittivi, in particolar modo reti neurali LSTM, è stato mostrato come sia possibile prevedere tale feature con un'approssimazione sufficientemente buona da renderla impiegabile nelle predizioni. Lo scenario di impiego a cascata delle stime della LSTM come feature da unire ai dati passati in input al modello MLP, il predittore principale, ha dato risultati incoraggianti, riportando un lievissimo scostamento tra predizioni del modello e dati reali target. Le principali limitazioni di questo lavoro consistono nell'aver impiegato, come tecniche di XAI, solamente SHAP e le EBMs, queste ultime escludendo la possibilità di interazioni tra features. Un interessante sviluppo futuro potrebbe essere, per quanto riguarda le EBMs, abilitare tale interazione e valutare se i risultati forniti siano concordi con quanto presentato dalla Heatmap con la correlazione di Spearman. Sul fronte più generale della XAI, potrebbe essere interessante valutare l'impiego di ulteriori tecniche, ad esempio afferenti alla sfera della computer vision, per l'analisi degli spettrogrammi, come ulteriore fonte di dati anche per quanto riguarda l'impatto dell' $F_{10.7}$ index.

Riferimenti Bibliografici

- [1] A. Chicarro, P. Martin, and R. Trautner, "The mars express mission: An overview," in *Mars Express: The scientific payload*, vol. 1240, European Space Agency, 2004, pp. 3–13.
- [2] B. Ferrari, M. Lippi, G. Ganzerli, M. Iori, R. Orosei, et al., "Explainable artificial intelligence for quality estimation of marsis observations," *FRONTIERS IN ARTIFICIAL INTELLIGENCE AND APPLICATIONS*, vol. 413, pp. 5471–5478, 2025.
- [3] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," *Advances in neural information processing systems*, vol. 30, 2017.
- [4] H. Nori, S. Jenkins, P. Koch, and R. Caruana, "Interpretml: A unified framework for machine learning interpretability," *arXiv preprint arXiv:1909.09223*, 2019.
- [5] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [6] S. M. Lundberg, S.-I. Lee, and contributors, *Shap (shapley additive explanations) python package*, <https://github.com/shap/shap>, 2018.
- [7] Y. Lou, R. Caruana, J. Gehrke, and G. Hooker, "Accurate intelligible models with pairwise interactions," in *Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining*, 2013, pp. 623–631.

Comparison of Solar Flux Distributions: Target vs. Prediction (Fold by Fold)




Figure 18: Confronto tra la distribuzione dei dati reali e le stime della LSTM.